Estadística III

Bootstrap

Alejandro López Hernández

FES Acatlán - UNAM

April 17, 2020

Índice

El bootstrap es un método de remeustreo el cual nos proporciona información acerca de un funcional T de una muestra $X_1, \ldots, X_n$. Una forma en la que se podría tener mas información de T es la situación cuando tenemos muchas muestras aleatorias, y podemos calcular T para cada una de las muestras, de esta manera podrías conocer mas acerca de la distribución de T.
Sin embargo, con el bootstrap no es necesario tener mas muestras ya que se realizan *remuestreos* de la unica muestra con la que contamos.

Definición 1

Sea $X_1, ..., X_n \sim F$ una muestra aleatoria y T un funcional de F. La distribución bootrsap de T está definida como

$$H_{Boot}(x) = \mathbb{P}_{\hat{F}_n}(T(X_1^*, ...X_n^*) \leq x)$$

Donde $X_1^*, ...X_n^*$ es una muestra aleatoria proveniente de $\hat{F}_n$

La distribución de $H_{Boot}(x)$ se puede utilizar para estimar quantiles o la varianza de T. La forma de calcular la varianza bootsrap es

Varianza Bootsrap

1. Extrae una muestra aleatoria de $X_1^*, ...X_n^* \sim \hat{F}_n$
2. Calcula $T_n^* = T(X_1^*, ...X_n^*)$
3. Repite el paso 1 y 2 B veces, para obtener $T_{n,1}^*, ..., T_{n,B}^*$
4. Sea

$$v_{\text{boot}} = \frac{1}{B}\sum_{b=1}^{B}\left(T_{n,b}^* - \frac{1}{B}\sum_{r=1}^{B} T_{n,r}^*\right)^2$$

Podemos utilizar v_{boot} para generar intervalos de confianza para T con la siguiente formula

$$T_n \pm z_{\alpha/2}\sqrt{v_{\text{boot}}}$$

Sin embargo, este intervalo solo es bueno si T_n tiene una distribución similar a la normal.

Sea $\theta = T(F)$ y $\hat{\theta}_n = T(\hat{F}_n)$, y definimos $R_n = \hat{\theta}_n - \theta$, sea $H(x)$ la distribución de R_n. Entonces definimos nuestro intervalo $C_n^* = (a, b)$ con

$$a = \hat{\theta}_n - H^{-1}(1 - \frac{\alpha}{2}) \quad \text{y} \quad b = \hat{\theta}_n - H^{-1}(\frac{\alpha}{2})$$

Notemos que $\mathbb{P}(a < \theta < b) = 1 - \alpha$ por lo tanto C_n^* es un intervalo de exactamente $1 - \alpha$ de confianza. Sin embargo, a y b dependen de la distribución de H pero se pueden estimar usando bootsrap.

Podemos estimar la distribución H como:

$$\hat{H}(r) = \frac{1}{B}\sum_{b=1}^{B} 1_{\{R^*_{n,b} \leq r\}}$$

Donde $R^*_{n,b} = \hat{\theta}^*_{n,b} - \hat{\theta}_n$, con la distribución empírica $\hat{H}(r)$ podemos estimar cuantiles de R_n, con $r^*_\beta = \inf\{x : \hat{H}(x) \geq \beta\}$, si θ^*_β es el cuantil β de θ se puede probar que $r^*_\beta = \theta^*_\beta - \hat{\theta}$ por lo tanto

$$\hat{a} = \hat{\theta}_n - \hat{H}^{-1}\left(1 - \frac{\alpha}{2}\right) = \hat{\theta}_n - r^*_{1-\alpha/2} = 2\hat{\theta}_n - \theta^*_{1-\alpha/2}$$

$$\hat{b} = \hat{\theta}_n - \hat{H}^{-1}\left(\frac{\alpha}{2}\right) = \hat{\theta}_n - r^*_{\alpha/2} = 2\hat{\theta}_n - \theta^*_{\alpha/2}$$

Intervalos de confianza Bootsrap

El intervalo pivotal de $1-\alpha\%$ confianza de Bootsrap es

$$C_n = \left(2\hat{\theta}_n - \hat{\theta}^*_{1-\alpha/2,B}, 2\hat{\theta}_n - \hat{\theta}^*_{\alpha/2,B}\right)$$